Detekce základní periody řeči

Ondřej Zikán

1 Úvod

Cílem tohoto projektu bylo na signálovém procesoru TMS320C6416 implementovat autokorelační metodu pro detekci základní periody segmentu řeči. Nejprve bude popsán princip autokorelační metody, následně bude rozebrán způsob implementace a nakonec budou zhodnoceny výsledky.

2 Autokorelační metoda

Autokorelace je definována jako

$$R(k) = \sum_{n=0}^{N-1-k} s(n)s(n+k), \quad k = k_{\min} \dots k_{\max}.$$

Jak je vidět ze vztahu signál je porovnáván se svojí zpožděnou verzí. Autokorelační funkce pak nabývá maxima, když je zpoždění (ve vzorci reprezentováno proměnnou k) rovno periodě signálu, pokud je vyloučen případ, kdy je zpoždění rovné nule. Cílem je tedy najít takové k, ve které má autokorelační funkce maximum. Nalezená hodnota k udává základní periodu v počtu vzorků. Tu lze převést na časovou jednotku se znalostí vzorkovací periody:

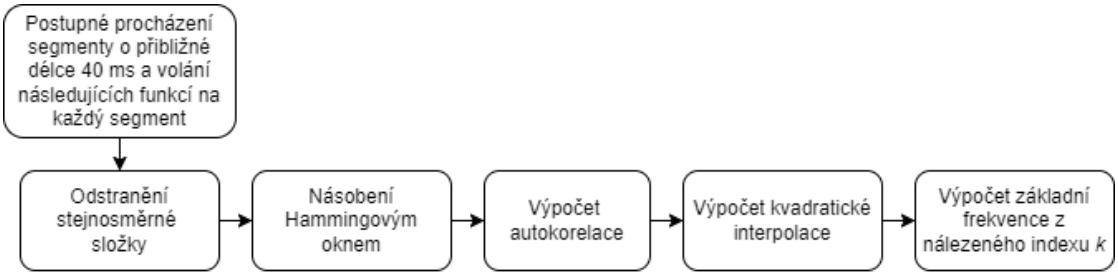
$$T_0[ms] = k/T_s$$

3 Implementace

Vzorky zvukového souboru obsahující nahrávku řeči jsou uložené v poli 16-bitových čísel. V souboru hello.c je vždy z pole vybrán počet vzorků odpovídající délce jednoho segmentu. Tento segment pak slouží jako vstup pro níže popisované funkce, které jsou definovány v souboru dsp.c. Pořadí volaných funkcí je znázorněné na diagramu [1]. Výsledek programu je zobrazen v terminálu jako pole čísel reprezentující odhad základní frekvence pro každý segment.

3.1 Odstranění stejnosměrné složky (funkce removeDC)

Nejprve je potřeba ze signálu odstranit stejnosměrnou složku pomocí filtru nebo odečtením průměrné hodnoty signálu od každého vzorku. Jelikož není třeba, aby program běžel v



Obrázek 1: Vývojový diagram

reálném čase, postačí druhá zmíněná metoda. Funkce byla pro ověření správného fungování testována na sinusovém signálu se známou stejnosměrnou složkou.

3.2 Násobení okénkovací funkcí (funkce applyHammingWin)

Dále je signál násoben okénkovací funkcí, která utlumí vzorky na okrajích segmentu, čímž se odstraňují artefakty vznikající kvůli skokové změně signálu způsobené useknutím. Je použito Hammingovo okno, které je definováno následovně:

$$w(n) = 0,54 - 0,46 \cos\left(2\pi \frac{n}{N-1}\right), \quad 0 \leq n \leq N.$$

kde N je délka segmentu. Vzorky Hammingova okna jsou předpočítány a uloženy do pole na začátku běhu programu (volána je funkce winInit).

3.3 Výpočet autokorelace (funkce autoCorrelation)

V dalším kroku se již počítá autokorelace. Definována je ve funkci autoCorrelation v souboru dsp.c. Jelikož očekávaná základní frekvence leží mezi 50 Hz až 400 Hz, jsou počítána pouze zpoždění (daných proměnnou k) v rozsahu odpovídajícímu těmto frekvencím. Pro vzorkovací frekvenci rovnou 44,1 kHz, odpovídá zpoždění k rozsahu 110 až 882 vzorkům ($f_s/50$).

3.4 Interpolace (funkce quadrInterpolation)

Nakonec proběhne kvadratická interpolace, která zredukuje nepřesnosti, které vznikají, když se skutečné maximum nachází mezi vzorky. Vzorek, ve kterém je nalezeno maximum, je společně s jeho sousedními vzorky proložen parabolou definovanou předpisem $y = ax^2 + bc + c$. Ze vztahu pro vrchol kvadratické funkce $x_{vrchol} = -\frac{b}{2a}$ lze pro tři stejně vzdálené body $(x_1, y_1), (x_2, y_2), (x_3, y_3)$ odvodit:

$$x_{vrchol} = -\frac{y_1 - y_3}{2(y_1 - 2y_2 + y_3)}$$

.

4 Výsledky

Program byl testován na 1-sekundové nahrávce hovořícího muže
(soubor tested_recording.wav [1]). Vzorkovací kmitočet nahrávky je 44,1 kHz. Vzorky byly pomocí Matlabu převedeny z formátu double na 16-bitová čísla v Q15 formátu (vynásobením konstantou 2^{15} a zaokrouhlením). Délka segmentu byla podle vzorkovací frekvence volena tak, aby odpovídala přibližně 40 ms. Posun dalšího segmentu od předchozího je dán tak, aby se segmenty překrývaly ze tří čtvrtin. Testovací nahrávka pak obsahuje 97 takových segmentů. Při autokorelaci není potřeba počítat všechny indexy k, jelikož očekávané základní frekvence řeči sahají pouze od 50 Hz do 400 Hz. Maximální a minimální indexy k odpovídající těmto kmitočtům jsou spolu s dalšími parametry v tabulce 1.

Vzorkovací frekvence [Hz]	44100	Počet segmentů	97
Délka segmentu	1764	minimální k	110
Posun segmentu	441	maximální k	882

Tabulka 1: Parametry použité pro autokorelaci

Stejný algoritmus byl implemetován v Matlabu a výsledky porovnány s výstupem ze signálového procesoru.

V obrázku 3 lze vidět výsledek autokorelační metody, která byla impelemtována v Matlabu. Odhady základních frekvencí jsou vyneseny v závislosti na čase. V grafu 2 je zobrazený časový průběh zvukového signálu. V časech, kdy je signál slabý, vznikají v druhém grafu špičky. To znamená, že nebylo nalezeno k větší než první spočítaný index a odhad pak vychází jako frekvence odpovídající tomuto počtu vzorků (tj. maximální očekávané frekvenci vyznačené červenou přímkou).

5 Závěr

Program funguje podle očekávání, jak je vidět z porovnání obou grafů. Rozdíl je patrný v čase 0,18 až 0,19 sekund, kde se v odhadu ze signálového procesoru objevuje špička navíc. Nejlepší výsledky jsou v místech, kde je signál dostatečně silný a příliš se dynamicky nemění, tj. v úseku od 0,30 do 0,54 sekund a pak přibližně od 0,69 sekund.

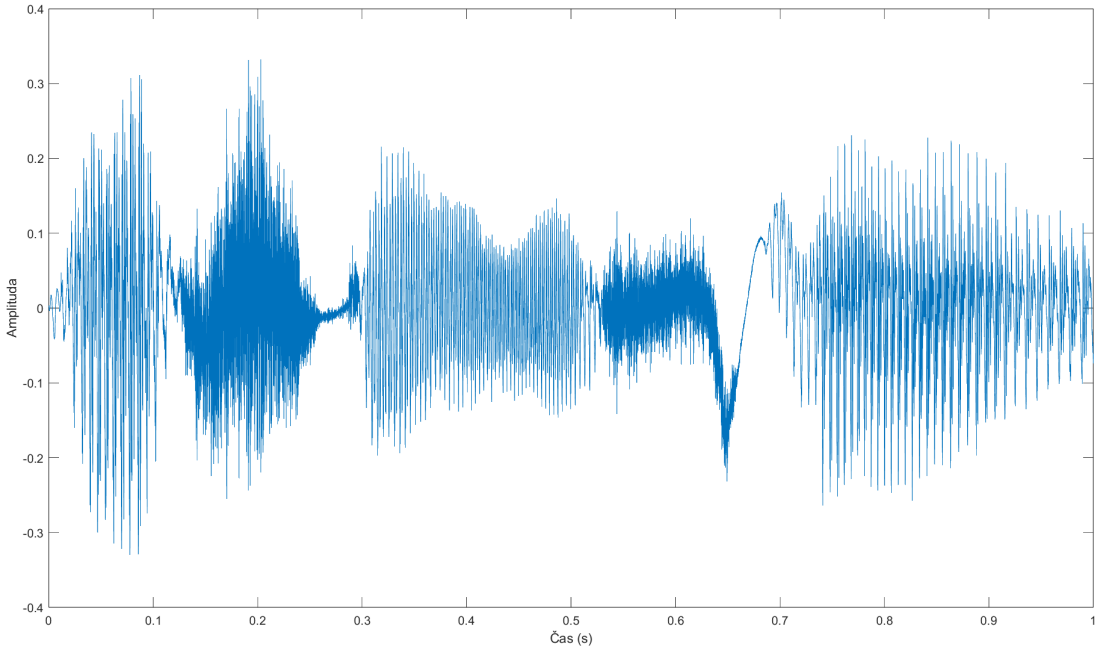
Periodu lze získat invertováním základní frekvence.

6 Obsah příohy

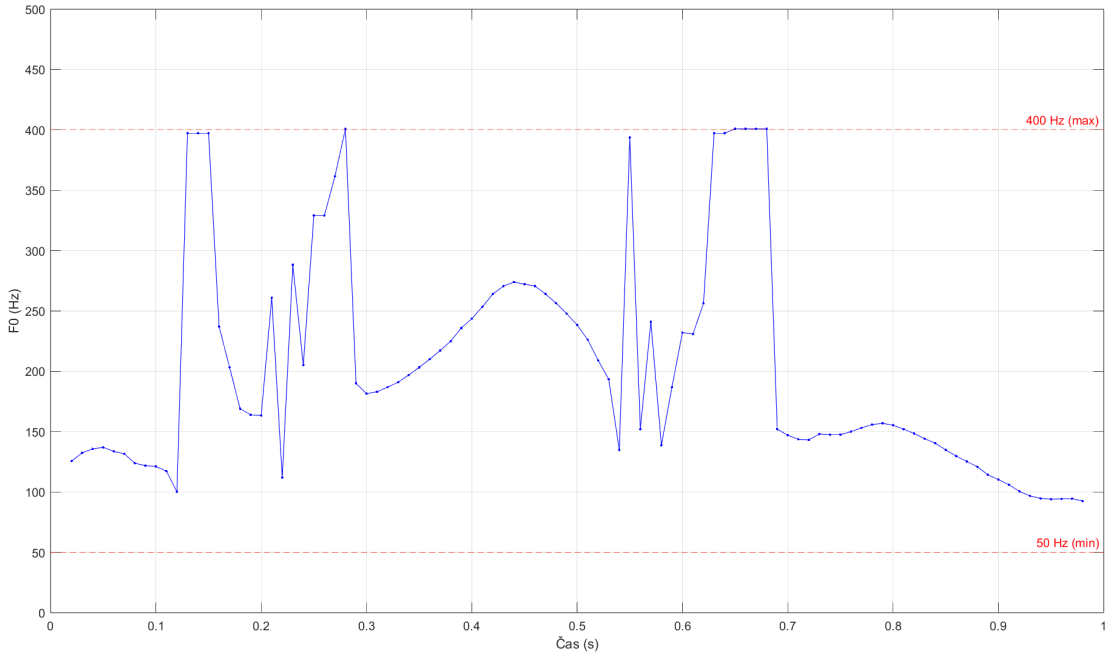
- *tested_recording.wav* - testovaný zvukový soubor
- *result_plot.m* - Matlab skript pro vynesení výsledného pole do grafu

[1] narhávka byla získána vystřižením vteřinového úseku z nahrávky dostupné zde: https://www.kaggle.com/datasets/pavanelisetty/sample-audio-files-for-speech-recognition

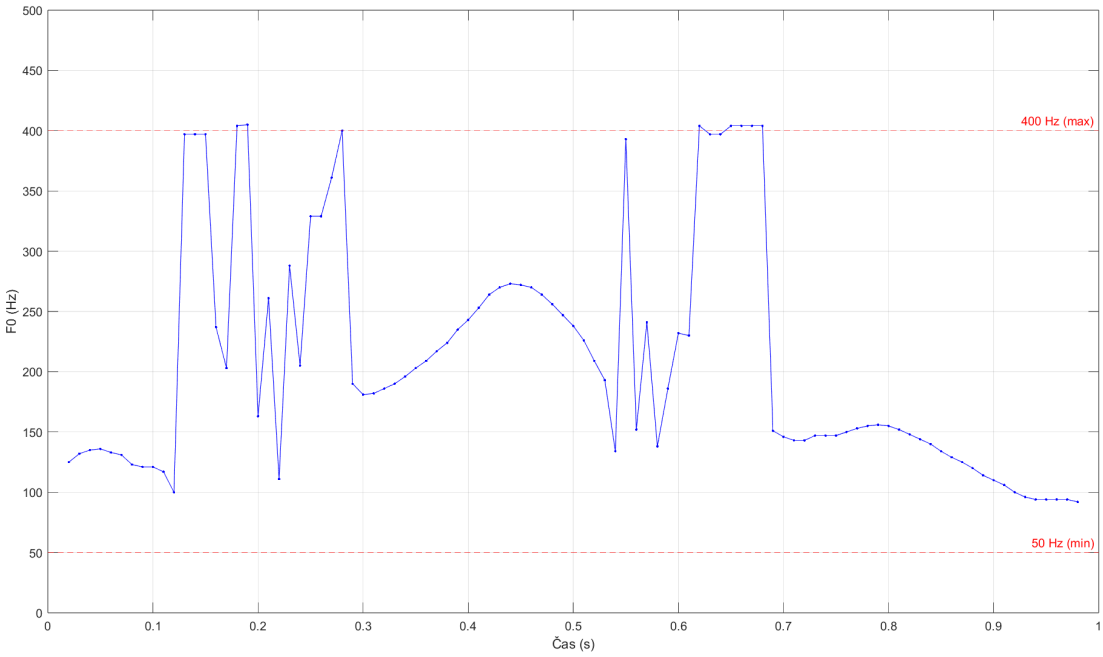
- *fundamental_frequency_estimation.m* - Matlab skript implementující stejný způsob odhadu základní frekvence (pro porovnání).
- složka *247821_script* - soubory pro spuštění programu na signálovém procesoru
  - dsp.c/dsp.h obsahuje implementované funkce
  - inputData.h obsahuje pole vstupních vzorků
  - hello.c - spuštění programu



Obrázek 2: Testovací nahrávka řeči



Obrázek 3: Odhad základní frekvence s použitím autokorelační metody v Matlabu



Obrázek 4: Odhad základní frekvence s použitím autokorelační metody na signálovém procesoru